

Informe Tecnico de Avance — Sumativa 1 (Fase 2)

Análisis estadístico del riesgo coronario a 10 años (Framingham Heart Study)

Estadística Computacional para la Toma de Decisiones · Magister en Ciencia de Datos e IA · UNAB

Dataset	Framingham Heart Study — TenYearCHD (4.240 registros, 16 variables)
Integrantes	Eduardo Garrido Sanhueza · Luis Espinosa Gutierrez · Mauricio Ortega Munoz · Wilson Arevalo Luna
Repositorio	GitHub: https://github.com/GRUPO3MCDI500/mcdi501-estadistica-computacional
RA / ID	RA1 · ID1.2 (descriptiva) · ID1.3 (estimacion/IC) · ID1.4 (pruebas de hipotesis)

4,240

registros

16

variables

15.19%

prevalencia CHD

13.73%

filas con NA

1. Introduccion al problema

Las enfermedades cardiovasculares son una de las principales causas de muerte a nivel mundial. El **Framingham Heart Study** es un estudio longitudinal pionero del que proviene este conjunto de datos: cada registro corresponde a un participante caracterizado por factores demograficos, conductuales y clinicos medidos en un examen basal. La variable objetivo, **TenYearCHD**, indica si la persona desarrollo enfermedad coronaria (CHD) en los 10 anos siguientes.

Problema de decision bajo incertidumbre: a partir de informacion clinica de rutina, queremos caracterizar que factores se asocian al riesgo coronario y estimar parametros poblacionales con su incertidumbre, como base para estrategias de prevencion y estratificacion de pacientes. El objetivo de esta fase no es predecir aun, sino sustentar conclusiones preliminares con evidencia: estadistica descriptiva, estimacion por intervalos y pruebas de hipotesis.

2. Preparacion de datos y reporte de calidad

El dataset contiene **4,240 registros** y **16 variables**, sin duplicados (0). Se identifican datos faltantes en: glucose (9.15%), education (2.48%), BPMeds (1.25%), totChol (1.18%), cigsPerDay (0.68%), BMI (0.45%), heartRate (0.02%). En total, **582 filas (13.73%)** tienen al menos un valor ausente. La variable objetivo esta **desbalanceada**: 644 casos positivos (15.19%) frente a 3596 negativos.

Decision metodologica. Para esta fase exploratoria se trabaja con eliminacion por lista en cada calculo (se usan los casos validos de cada variable), preservando el maximo de informacion sin imputar. El desbalance se considera al interpretar la prevalencia. Tanto la imputacion de faltantes como el tratamiento del desbalance se abordaran formalmente en la fase de modelado (Seccion 8).

3. Analisis exploratorio: variables numericas (ID1.2)

Variable	n	Media	Mediana	Desv.	CV%	Min	Q1	Q3	Max	Asim.	Curt.
Edad	4240	49.58	49.0	8.57	17.29	32.0	42.0	56.0	70.0	0.229	-0.99
Colesterol	4190	236.7	234.0	44.59	18.84	107.0	206.0	263.0	696.0	0.872	4.13
P. sistolica	4240	132.35	128.0	22.03	16.65	83.5	117.0	144.0	295.0	1.145	2.157
P. diastolica	4240	82.9	82.0	11.91	14.37	48.0	75.0	90.0	142.5	0.713	1.275
IMC	4221	25.8	25.4	4.08	15.81	15.54	23.07	28.04	56.8	0.982	2.657
Frec. card.	4239	75.88	75.0	12.03	15.85	44.0	68.0	83.0	143.0	0.644	0.907
Glucosa	3852	81.96	78.0	23.95	29.23	40.0	71.0	87.0	394.0	6.215	58.704
Cigarrillos/dia	4211	9.01	0.0	11.92	132.38	0.0	0.0	20.0	70.0	1.247	1.019

La mayoría de las variables clínicas son **asimétricas a la derecha** (media > mediana). El caso extremo es **glucosa** (asimetría 6.215, curtosis 58.704), por la cola de pacientes diabéticos. El mayor coeficiente de variación es glucosa (29.23%); la edad es la más simétrica.




Figura 1. Distribucion de variables continuas (media en rojo, mediana en verde).




Figura 2. Boxplots estandarizados: glucosa, colesterol y presion concentran los valores atipicos.

4. Analisis exploratorio: variables categoricas (ID1.2)

Variable	Frecuencias absolutas y relativas
CHD a 10 anos	Sin CHD: 3596 (84.81%) · Con CHD: 644 (15.19%)
Sexo	Mujer: 2420 (57.08%) · Hombre: 1820 (42.92%)
Tabaquismo	No fuma: 2145 (50.59%) · Fuma: 2095 (49.41%)
Hipertension	No: 2923 (68.94%) · Si: 1317 (31.06%)
Diabetes	No: 4131 (97.43%) · Si: 109 (2.57%)
Nivel educativo	Basica: 1720 (41.6%) · Media/GED: 1253 (30.3%) · Tec/Univ parcial: 689 (16.66%) · Universitaria: 473 (11.44%)




Figura 3. Frecuencias de las principales variables categoricas (porcentaje sobre el total).

5. Analisis bivariado




Figura 4. Matriz de correlacion de Pearson (variables numericas).

Presion sistolica y diastolica estan fuertemente correlacionadas ($r=0.78$) y ambas con la edad. Las asociaciones individuales son moderadas: el riesgo coronario es **multifactorial**, ninguna variable lo explica por si sola. **Correlacion no implica causalidad**: estas relaciones describen patrones, no mecanismos causales.




Figura 5. La prevalencia de CHD crece de forma marcada con la edad.

6. Estimacion puntual e intervalos de confianza (ID1.3)

Estimamos parametros poblacionales sobre cuatro variables numericas relevantes. Para las medias usamos el intervalo basado en la distribucion t de Student (desviacion poblacional desconocida); para la prevalencia de CHD —una proporcion— el intervalo de **Wilson**, mas adecuado que el de Wald con clases desbalanceadas.

Parametro	Estimacion puntual	IC 95%	n
Presion sistolica (mmHg)	132.35	[131.69, 133.02]	4240
Colesterol total (mg/dL)	236.7	[235.35, 238.05]	4190
IMC (kg/m ²)	25.8	[25.68, 25.92]	4221
Glucosa (mg/dL)	81.96	[81.21, 82.72]	3852
Prevalencia CHD a 10 anos (%)	15.19%	[14.14, 16.3] (Wilson)	4240

Con 95% de confianza, la presion sistolica media poblacional esta entre 131.69 y 133.02 mmHg. Los intervalos son estrechos por el gran tamano muestral ($n \sim 4.200$): a mayor n , menor error estandar. La prevalencia de CHD se estima en 15.19% (IC95% [14.14, 16.3]). **Limitaciones:** los IC suponen muestreo aleatorio; los datos faltantes (glucosa ~9%) reducen el n efectivo y podrian sesgar la estimacion si no son aleatorios; el intervalo cuantifica incertidumbre de muestreo, no errores de medicion.

7. Pruebas de hipotesis (ID1.4)

Se aplican **dos tipos de prueba**, seleccionados segun el tipo de variable: (A) prueba **t de Welch** para comparar medias de variables numericas entre grupos (CHD vs. no CHD), y (B) prueba **chi-cuadrado de independencia** para asociar variables categoricas con CHD. Nivel de significancia **alfa = 0.05**, estandar en investigacion biomedica, que acota en 5% la probabilidad de error tipo I.

Verificacion de supuestos

Normalidad: los graficos Q-Q (Figura 6) y la prueba de Shapiro-Wilk ($p < 0.001$) indican que las variables se desvian de la normalidad, con asimetria moderada (sysBP skew~1.06). Sin embargo, con $n \sim 4.200$ el **Teorema del Limite Central** garantiza que la distribucion de la media muestral es aproximadamente normal, por lo que la prueba t es robusta. **Homogeneidad de varianzas:** la prueba de Levene rechaza la igualdad de varianzas para la presion sistolica ($p < 0.001$), lo que justifica usar la version de **Welch** (no asume varianzas iguales). Para chi-cuadrado se verifico que todas las frecuencias esperadas superan 5, supuesto que se cumple.




Figura 6. Graficos Q-Q: los puntos se alejan de la recta en las colas (asimetria a la derecha).

Prueba A — t de Welch (medias por desenlace)

H0: $\mu(\text{con CHD}) = \mu(\text{sin CHD})$ | **H1:** $\mu(\text{con CHD}) \neq \mu(\text{sin CHD})$

Variable	M. sin CHD	M. con CHD	Dif.	t	gl	p	d Cohen	Decision
Edad	48.76	54.15	5.38	15.592	916.1	<0.001	0.644	Rechaza H0
P. sistolica	130.34	143.62	13.28	12.012	783.8	<0.001	0.617	Rechaza H0
P. diastolica	82.17	86.98	4.81	8.242	800.3	<0.001	0.409	Rechaza H0
Colesterol	235.15	245.39	10.24	5.01	832.3	<0.001	0.23	Rechaza H0
Glucosa	80.68	89.01	8.33	4.841	639.7	<0.001	0.35	Rechaza H0
IMC	25.67	26.53	0.86	4.489	815.8	<0.001	0.211	Rechaza H0
Frec. cardiaca	75.76	76.53	0.77	1.472	877.3	0.141	0.064	No rechaza

Seis de siete variables muestran diferencias significativas. Las mas fuertes son edad ($d=0.644$) y presion sistolica ($d=0.617$): la presion sistolica media es 143.62 mmHg con CHD vs. 130.34 sin CHD (diferencia 13.28 mmHg, IC95% [11.11, 15.45], $t=12.012$, $p<0.001$). La **frecuencia cardiaca no discrimina** ($p=0.14$): resultado negativo util que evita sobreinterpretar.




Figura 7. Presion sistolica segun desenlace (rombo = media).

Prueba B — Chi-cuadrado de independencia (factores categoricos)

H0: el factor es independiente de CHD | **H1:** existe asociacion

Factor	chi2	gl	p	V de Cramer	% CHD (No / Si)	Decision
Hipertension	132.456	1	<0.001	0.177	10.91% / 24.68%	Rechaza H0
Diabetes	38.482	1	<0.001	0.095	14.62% / 36.7%	Rechaza H0
Sexo (hombre)	32.618	1	<0.001	0.088	12.44% / 18.85%	Rechaza H0
Tabaquismo	1.497	1	0.221	0.019	14.5% / 15.89%	No rechaza

Hallazgo relevante: la **hipertension** muestra la asociacion mas fuerte ($\chi^2=132.456$, $p<0.001$): la prevalencia de CHD pasa de 10.91% a 24.68%. Diabetes y sexo masculino tambien se asocian significativamente. En cambio, el **tabaquismo actual no resulta significativo** ($p=0.22$): su efecto sobre el riesgo a 10 anos podria estar mediado por otros factores o requerir la intensidad (cigarrillos/dia) en vez del indicador binario. Las V de Cramer (<0.2) confirman asociaciones reales pero de magnitud modesta.




Figura 8. Prevalencia de CHD segun tabaquismo, hipertension y diabetes.

8. Interpretacion preliminar y proximos pasos

Sintesis para la decision. El riesgo coronario a 10 anos se concentra en perfiles de mayor edad, presion arterial, glucosa, y en presencia de hipertension o diabetes. La cuantificacion de la incertidumbre (IC y valores p) permite distinguir senales reales de ruido muestral antes de comprometer recursos de prevencion. Esto respalda estrategias de **estratificacion de riesgo**: priorizar seguimiento en los subgrupos identificados.

Limitaciones. (1) Datos observacionales: asociacion no implica causalidad. (2) Deteccion basada en factores de riesgo, no en enfermedad confirmada. (3) Desbalance de clases y faltantes (glucosa ~9%) exigen cautela. (4) Conclusiones poblacionales no se trasladan automaticamente a un individuo.

Proximos pasos (Fase 3 — modelado). (i) Imputacion justificada de faltantes (mediana o KNN) y comparacion de su impacto; (ii) tratamiento del desbalance (remuestreo / ponderacion de clases); (iii) modelos de clasificacion (regresion logistica como linea base, luego modelos no lineales) con validacion y metricas adecuadas al desbalance (AUC, recall, F1); (iv) analisis multivariado para controlar factores de confusion como el observado en tabaquismo.

Reproducibilidad: analisis en Python (pandas, numpy, scipy, matplotlib, seaborn). El notebook adjunto (.ipynb) regenera todas las tablas y figuras sin errores. Fuente: Framingham Heart Study (subconjunto publico).